

Documents structurés


Cours 2

Nassim ZELLAL

Les nœuds en XML

- Nœud document/nœud de document (document node).
 - Nœud élément/nœud d'élément (element node).
 - Nœud texte/nœud de texte (text node).
 - Nœud attribut/nœud d'attribut (attribute node).
 - Nœud commentaire/nœud de commentaire (comment node).
-

Structure générale d'un document XML



Le document XML

- Votre document XML :
 - Commence par une **déclaration XML** (facultative et non répétable).
 - Contient un seul **élément racine** (obligatoire et non répétable).
-

Le document XML

- Une déclaration XML.
- Des instructions de traitement (CSS, XSL(T)).
- Une déclaration de type de document (DTD).
- DTD → Document Type Declaration.
- -----
- `<?xml version="1.0" encoding="iso-8859-1"?>`
- `<?xml-stylesheet type="text/css" href="feuille.css"?>`
- `<!DOCTYPE contacts SYSTEM "usthb.dtd">`
- -----
- Des commentaires peuvent être insérés entre ces composants à n'importe quel endroit sauf avant la déclaration XML.

Le document XML

- `<?xml version="1.0" encoding="utf-8"?>`
- `<?xml-stylesheet type="text/css" href="feuille.css"?>`
- `<!DOCTYPE itineraire SYSTEM "usthb.dtd">`
- `<!--itinéraire-->`
- `<itineraire>`
- `<etape distance="0km">départ</etape>`
- `<etape distance="13km">tourner à droite</etape>`
- `<etape distance="22km">arrivée</etape>`
- `</itineraire>`


La déclaration XML

- La déclaration XML prend par exemple la forme suivante :
- `<?xml version="1.0" encoding="iso-8859-1"?>`
- La déclaration XML est facultative et non répétable, **mais il est fortement recommandé de l'utiliser.**
- Si elle est présente, elle doit précéder tout autre composant XML.
- Les informations concernant l'encodage sont facultatives mais doivent respecter l'ordre indiqué, si elles figurent (version / encoding).
- La version est celle du langage XML utilisé.
- **Lorsque le document XML est encodé en UTF-8/UTF-16 (encodages par défaut en XML), il n'est pas nécessaire de mettre l'attribut « encoding ». Dans le cas contraire, on doit préciser l'encodage dans la valeur de cet attribut.**

Les instructions de traitement

- `<?xml-stylesheet type="text/css" href="feuille.css"?>`
- `<?xml-stylesheet type="text/xsl" href="feuille.xsl"?>`
- Les instructions de traitement sont facultatives.

La DTD (Document Type Declaration)



La DTD (Document Type Declaration)

- `<!DOCTYPE Élément_racine SYSTEM "URI">` → URI (Uniform Resource Identifier).
- `<!DOCTYPE contacts SYSTEM "usthb.dtd">` (stockée localement et disponible via son URI de type URL).
- -----
- `<!DOCTYPE Élément_racine PUBLIC "FPI" "URI">`
`<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Strict//EN"`
`"http://www.w3.org/TR/xhtml1/DTD/xhtml1-strict.dtd">` (publiée sur Internet, disponible via son URI de type URL).
- -----
- L'URL (Uniform Resource Locator) de la DTD est :
- Soit le nom d'un fichier local, tel que "usthb.dtd"
- Soit un chemin débutant par un protocole de transfert (suivi de `://`) comme `ftp` ou `http`, par exemple : `<!DOCTYPE contacts SYSTEM "http://www.usthb.dz/cours/bibliographie.dtd">`

La DTD (Document Type Declaration)

- `<!DOCTYPE` **Élément_racine** **PUBLIC** "FPI" "URI">
`<!DOCTYPE` **html** **PUBLIC** "-//W3C//DTD XHTML 1.0 Strict//EN"
`"http://www.w3.org/TR/xhtml1/DTD/xhtml1-strict.dtd">` (publiée sur Internet, disponible via son URI de type URL).
- -----
- `"-//W3C//DTD XHTML 1.0 Strict//EN"` → C'est un FPI (Formal Public Identifier = identificateur public formel).
- `"http://www.w3.org/TR/xhtml1/DTD/xhtml1-strict.dtd"` → URI de type URL de la DTD.

La DTD (Document Type Declaration)

<!--

Extensible HTML version 1.0 Strict DTD

This is the same as HTML 4 Strict except for
changes due to the differences between XML and SGML.

Namespace = <http://www.w3.org/1999/xhtml>

For further information, see: <http://www.w3.org/TR/xhtml1>

Copyright (c) 1998-2002 W3C (MIT, INRIA, Keio),
All Rights Reserved.

Page affichée sur un navigateur Web.

<http://www.w3.org/TR/xhtml1/DTD/xhtml1-strict.dtd> (URI de type URL)

Espaces de noms par défaut (sans préfixes) - implicites - URN (Uniform Resource Name)

```
<?xml version="1.0"?>  
<book xmlns='urn:loc.gov:books'>  
  <title>Cheaper by the Dozen</title>  
</book>
```

L'URI d'un espace de nom (xmlns = name space) de type URN (Uniform Resource Name) est un nom donné à un document indépendamment de la façon d'y accéder. Un exemple d'URN est l'URN books.

Espace de noms spécifiques (avec préfixes) - explicites - URN

```
<?xml version="1.0"?>
<bk:book xmlns:bk='urn:loc.gov:books'
          xmlns:isbn='urn:ISBN:0-395-36341-6'>
  <bk:title>Cheaper by the Dozen</bk:title>
  <isbn:number>1568491379</isbn:number>
</bk:book>
```

Un autre exemple typique d'URN est l'URN formé à partir du numéro ISBN d'un livre comme urn:isbn:978-2-7117-2077-4. Cet URN identifie le livre Cheaper by the Dozen, mais n'indique pas comment l'obtenir.

Espaces de noms mixtes (avec et sans préfixes) - URN

```
<?xml version="1.0"?>
<book xmlns='urn:loc.gov:books'
      xmlns:isbn='urn:ISBN:0-395-36341-6'>
  <title>Cheaper by the Dozen</title>
  <isbn:number>1568491379</isbn:number>
</book>
```

Élément racine - XML

- L'élément racine est obligatoire et ne peut être répété dans un document XML.
- L'élément racine peut être vide comme dans l'exemple suivant.
- `<?xml version="1.0" encoding="iso-8859-1"?>`
- `<racine/>`
- -----
- `<?xml version="1.0" encoding="iso-8859-1"?>`
- `<racine>`
- `.....`
- `</racine>`

Attributs et données (représentation de l'information) en XML

- `<person    firstname="John"    lastname="Smith"/>`
(élément XML vide - EMPTY). Utilisation d'**attributs** pour stocker l'information.
-

- `<person>`
 - `<firstname>John</firstname>`
 - `<lastname>Smith</lastname>`
 - `</person>`
-

Documents bien formés (well formed) - caractères spéciaux

- Pour être un document XML bien formé, ce dernier doit respecter les règles de syntaxe XML (voir cours 1).
- Certains caractères doivent être échappés (déspécialisés) : **&** (nom d'entité HTML **&** ou numéro d'entité HTML **&** (code ASCII en décimal)) ou **<** (nom d'entité html **<** ou numéro d'entité HTML **<** (code ASCII en décimal)).
- Des entités HTML de type entité nommée ou entité numérique sont utilisées pour afficher sur le navigateur certains caractères spéciaux :
- [**https://www.w3schools.com/html/html_entities.asp**](https://www.w3schools.com/html/html_entities.asp)

Documents bien formés - well formed

- `<?xml version="1.0"?>`
 - `<racine>`
 - `<para>Bonjour le &<emphase>monde!<`
`</emphase></para>`
 - `</racine>`
- ▼ `<racine>`
- ▼ `<para>`
 Bonjour le &
 <emphase>monde!< </emphase>
 </para>
 </racine>

Document XML « well-formed.xml »

Documents mal formés - not well formed

- `<?xml version="1.0"?>`
- `<racine>`
- `<para>Bonjour le & <emphase>monde < </emphase></para>`
- `</racine>`
- **Document XML ouvert avec Firefox**

Erreur d'analyse XML : mal formé

Emplacement : file:///C:/Users/user/Desktop/not-well-formed.xml

Numéro de ligne 2, Colonne 19 :

```
<para>Bonjour le & <emphase>monde < </emphase></para>
-----^
```


Documents valides (DTD)

- Un document est valide s'il respecte une grammaire DTD (Document Type Definition).
 - Une DTD peut être de type « PUBLIC » ou « SYSTEM ».
 - On peut accéder à la DTD via sa « Déclaration de Type de Document ».
- ➔ Voir « **personne.xml** » est valide par rapport à la grammaire « **usthb.dtd** ».
-

Documents valides (DTD)

```
<?xml version="1.0"?>
<!DOCTYPE contacts SYSTEM "usthb.dtd">
<contacts>
  <personne>
    <nom>Chazalon</nom>
    <prenom>Grégory</prenom>
    <dateDeNaissance>1977-07-09</dateDeNaissance>
    <adresse pays="France"/>
    <email>gchazalon@voila.fr</email>
    <telephone>01 23 45 67 89</telephone>
  </personne>
  <personne>
    <nom>Lemoine</nom>
    <prenom>Joséphine</prenom>
    <dateDeNaissance>1977-01-06</dateDeNaissance>
    <adresse pays="France"/>
    <email>joe6@voila.fr</email>
  </personne>
</contacts>
```

```
<!ELEMENT contacts (personne+)>
<!ELEMENT personne (nom, prenom, dateDeNaissance, adresse, email, telephone?)>
<!ELEMENT nom (#PCDATA)>
<!ELEMENT prenom (#PCDATA)>
<!ELEMENT dateDeNaissance (#PCDATA)>
<!ELEMENT adresse EMPTY>
<!ELEMENT email (#PCDATA)>
<!ELEMENT telephone (#PCDATA)>
<!ATTLIST adresse pays CDATA #REQUIRED>
```



Différence entre HTML et XHTML

- Le **XHTML** est une réécriture du **HTML** dont l'objectif est de permettre une transition vers le langage **XML**.
- **XHTML 1.0** : c'est la première version, qui est déclinée en plusieurs versions : **strict** et **transitional**. C'est une reformulation de HTML avec une syntaxe XML.
- **XHTML 1.1** : c'est une version, qui fait un pas de plus dans la transition **HTML** → **XML**. Cette version possède également deux versions : **strict** et **transitional**.
- **XHTML 2.0** : en juillet 2009, le W3C a finalement abandonné le développement de la version **XHTML 2.0** pour se consacrer au **HTML 5**.
- **XHTML 5** : c'est la version **XML** de **HTML 5**.

Quelques différences entre HTML et XHTML

- Toute balise ouvrante doit être fermée, mais il y a quelques exceptions ou les éléments n'ont pas de contenu et sont auto-fermants (vides/empty), c'est le cas du saut de ligne `<br />`.
- Les éléments «vides» (auto-fermants) sont écrits avec une barre oblique finale (exemple: `<br />`).
- Les noms des éléments et des attributs (validation par rapport à une DTD, voir exemple de l'attribut « pays » du document « peronne.xml ») sont écrits en **minuscules (case sensitive)**.
- Tous les **attributs** doivent avoir une **valeur**. Et cette dernière doit être entourée de guillemets.
- Les éléments HTML doivent être **correctement imbriqués**.
- `<p><strong>contenu</strong></p>`
- **Au lieu de**
- `<p><strong>contenu</p></strong>`.

XHTML strict et transitional

- Le mode « **transitional** » indique au navigateur que la page utilise la syntaxe XHTML, mais utilise certains éléments en provenance du HTML. Ce DOCTYPE permet aux sites en HTML de passer en XHTML 1.0 avec un minimum d'efforts (respecter la syntaxe comme la fermeture des éléments).
 - Le mode « **strict** » est plus rigoureux que le mode « **transitional** ». Il n'autorise pas, par exemple, l'utilisation des attributs et des éléments de présentation. Ces derniers doivent être remplacés par des styles **CSS**.
 - Le mode « **strict** » correspond donc au niveau supérieur de la conception XHTML, tandis que **Transitional** permet une transition en douceur entre HTML et XML.
- <http://www.zvon.org/xxl/xhtmlReference/Output/comparison.html>
=> Voir codes (X)HTML (**strict-xhtml.html**, **transitional-xhtml.html**)

Déclaration de type de document (XHTML)

- `<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Transitional//EN" "http://www.w3.org/TR/xhtml1/DTD/xhtml1-transitional.dtd">`
- `<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Strict//EN" "http://www.w3.org/TR/xhtml1/DTD/xhtml1-strict.dtd">`

=> Voir codes (X)HTML (strict-xhtml.html, transitional-xhtml.html)

Déclaration de type de document (XHTML Transitional)

```
<?xml version="1.0"?>
<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Transitional//EN"
"http://www.w3.org/TR/xhtml1/DTD/xhtml1-transitional.dtd">
<html xmlns="http://www.w3.org/1999/xhtml">
  <head>
    <title> Transitional DTD XHTML Example </title>
  </head>
  <body text="red">
    <b>bonjour</b>
    Du texte
    <center>
      <font color="blue">Bonjour</font>
    </center>
    <p>transitional XHTML</p>
  </body>
</html>
```

XHTML Transitional.

Déclaration de type de document (XHTML Strict)

```
<?xml version="1.0"?>
<!DOCTYPE html PUBLIC "-//W3C//DTD XHTML 1.0 Strict//EN"
"http://www.w3.org/TR/xhtml1/DTD/xhtml1-strict.dtd">
<html xmlns="http://www.w3.org/1999/xhtml">
  <head>
    <title> Strict DTD XHTML Example </title>
  </head>
  <body text="red"><!--il est interdit d'utiliser
l'attribut "text" (présentation) dans <body>-->
<!--il est interdit d'écrire du texte en dehors d'un élément <p>-->
  du texte
  <center><!--il est interdit d'utiliser l'élément <center> (présentation)-->
  <p>Du texte centré</p>
  </center>
  <p>
    <br />
    <br />
    <select name="day">
      <option selected="selected">Monday</option>
      <option>Tuesday</option>
      <option>Wednesday</option>
    </select>
  </p>
  <font color="blue">Bonjour</font><!--il est interdit d'utiliser
l'élément "font" (présentation)-->
  <b>Texte en gras</b><!--il est interdit de mettre un élément <b>
en dehors d'un élément <p> -->
</body>
</html>
```

XHTML Strict

Exercice

- Corriger (justesse de forme et validation) le document : **cours2.html**
 - Ne pas supprimer des éléments ou du contenu de ce document.
 - Ne pas modifier l'encodage du document.
-

Éditeurs XML

- XMLCooktop (Cooktop)
 - **XML Copy Editor**
 - **Exchanger XML Editor**
 - Notepad++ (XML Tools)
-

Mon courriel

zellal.nassim@gmail.com
